

Université de BOUIRA
Département d'informatique

Support pour L2

Théorie des langages

Elaboré par :
HAMID Rabah
r_hamid@esi.dz



Plan du cours

1

•Notions sur la théorie des langages. (Mots , Langages)

• **Alphabets - Mots - Langages**



Plan du cours

2

• Système générateur de langages (Grammaire)

- **Système générateur de langage (Grammaire)**
- **Classification de Chomsky des grammaires**
- **Hiérarchie de Chomsky**



Plan du cours

3

• **Langages réguliers (Les automates à états finis).**

- **Automates AEF déterministes**
- **Automates AEF non déterministes**
- **Automate AEF et grammaires régulières a droite**
- **Propriétés de fermeture de la classe des langages réguliers**



Plan du cours

3

- **Langages réguliers (Les automates à états finis).**

- **Des expressions aux automates**
- **Des automates aux expressions régulières**
- **Stabilité de la régularité**



Plan du cours


4

• Langages algébriques (Les automates à pile).

- Premières définitions
- Arbres d'analyse
- Une illustration de l'ambiguïté
- A propos de la hiérarchie de Chomsky
- Formes normales
- Lemme de la pompe
- Automates à pile
- Stabilité des caractères algébriques




Objectif





Objectif





Objectif

Différentes phases de la compilation		Outils théoriques utilisés
Phases d'analyse	analyse lexicale (scanner)	expressions régulières automates à états finis
	analyse syntaxique (parser)	grammaires automates à pile
	analyse sémantique	traduction dirigée par la syntaxe
Phases de production	génération de code	traduction dirigée par la syntaxe
	optimisation de code	
Gestions parallèles	table des symboles	
	traitement des erreurs	



DÉFINITIONS

- **Un Alphabet** : est un ensemble non vide et fini de symboles (ou caractères). Il est également appelé le vocabulaire.

Ex $V = \{a, b, c\}$ $V = \{A..Z\}$ $V = \{1..9\}$

- **Un Mot** défini sur un alphabet V est une Suite finie d'éléments de V

Ex $V = \{a, b\}$ ab , aab , abb $aaaab$ sont des mots de V

$V = \{0, 1\}$ 10 , 110 , sont des mot de V

ε : le mot vide de V

- **La Longueur du mot** w est notée $|w|$ est le nombre de lettres qui forme ce mot . $|\varepsilon| = 0$

Ex : $w = ab \Rightarrow |w| = 2$

$w = abca \Rightarrow |w| = 4$



DÉFINITIONS

➤ Concaténation des mots

Soient $w1$ et $w2$ deux mots définis sur l'alphabet V . La concaténation de $w1$ et $w2$ est un mot w défini sur le même alphabet. w est obtenu en écrivant $w1$ suivi de $w2$, en d'autres termes, on colle le mot $w2$ à la fin du mot $w1$:

Ex : $w1 = abbc$ $w2 = bbc$ $w = w1.w2 = abbcbbc$

$w1 = a1...an$, $w2 = b1b2...bm$ $w = w1.w2$ $w1w2 = a1...anb1b2...bm$

➤ Propriété de la concaténation

Soient w , $w1$ et $w2$ trois mots définis sur l'alphabet V :

- ✓ $|w1.w2| = |w1| + |w2|$;
- ✓ $(w1.w2).w3 = w1.(w2.w3)$ (la concaténation est associative) ;
- ✓ $w.\varepsilon = \varepsilon.w = w$ (ε est un élément neutre pour la concaténation) ;



DÉFINITIONS

➤ Exposant

L'opération $w.w$ est notée par w^2 . En généralisant, on note $w^n = \underbrace{w \dots w}_{n \text{ fois}}$, $w^0 = \varepsilon$

Ex : $a^3 = aaa$, $(ab)^4 = abababab$

➤ Mot miroir

Soit $w = a_1 a_2 \dots a_n$ un mot sur V . On appelle mot miroir de w et on le note par w^R le mot obtenu en écrivant w l'envers, C.A.D $w^R = a_n \dots a_2 a_1$. Il est donc facile de voir que $(w^R)^R = w$.

Ex $w = aabbc$

$w^R = cbbaa$

NB : Certains mots, appelés palindromes, sont égaux à leur miroir.

➤ Fermeture de Kleene :

Soit V un alphabet .

On dénote par V^* l'ensemble de toutes les séquences finies de symboles de V .

Ex $V = \{a, b, c\}$

$V^* = \{ \varepsilon, a, b, c, aa, aaabbc, bbccca, \dots \}$ ensemble infini



DÉFINITIONS

➤ **V^*** : Est exactement l'ensemble de tout les mots construits sur un alphabet de langueu
 $0,1,2,3,\dots$

$$V^* = V^0 + V^1 + V^2 + \dots$$

$V^0 = \{\epsilon\}$, $V^1 = \text{tout les mots de longueur } 1 \dots$

➤ **Occurrence d' une lettre :**

Occurrence d'une lettre **a** dans un mot **w** on dénote $|w|_a$ le nombre
d'apparition de la lettre **a** dans le mot **w**

Ex : $|abcca|_a = 2$ $|abab|_c = 0$



DÉFINITIONS

➤ Préfixe et suffixe

Soit w un mot défini sur un alphabet V . Un mot x (resp. y) formé sur V est un **préfixe** (resp. **suffixe**) de w s'il existe un mot u formé sur V (resp. v formé sur V) tel que $w = xu$ (resp. $w = vy$).

Si $w = a_1a_2...a_n$

alors tous les mots de l'ensemble $\{\epsilon, a_1, a_1a_2, a_1a_2a_3, ..., a_1a_2...a_n\}$ sont des préfixes de w .

De même,

tous les mots de l'ensemble $\{\epsilon, a_n, a_{n-1}a_n, a_{n-2}a_{n-1}a_n, ..., a_1a_2...a_n\}$ sont des suffixes de w .

Ex $w = aabca$ $\{\epsilon, , a, aa, aab, aabc, aabca\}$ sont des préfixes de w
 $\{\epsilon, a, ca, bca, abca, aabca\}$ sont des suffixes de w .

➤ Mots conjugués

Deux mots x et y sont dits conjugués s'il existe deux mots u et v tels que : $x = uv$ et $y = vu$.



NOTIONS SUR LES LANGAGE

Un langage : est un ensemble (fini ou infini) de mots définis sur un alphabet donné.

Exemples :

- Langage des nombre binaires définies sur l'alphabet $\{0, 1\}$ (infini) ;
- Langage des mots de longueur 2 défini sur l'alphabet $\{a, b\} = \{aa, ab, ba, bb\}$;
- $L = \{w \in V^* \mid w = 0w' \text{ avec } w' \in V^*\}$; Tout les mots commençant par zéro
- $L = \{a^m b a^n : m \in \mathbb{N} \text{ et } n \in \mathbb{N}\}$

Opérations sur les langages

- **L'union** : notée par $+$ ou $|$ plutôt que $\cup$. $L1 + L2 = \{w \mid w \in L1 \text{ ou } w \in L2\}$;
- **L'intersection** : $L1 \cap L2 = \{w \mid w \in L1 \text{ et } w \in L2\}$;
- **Le complément** : $L = \{\text{tous les mots } w \text{ sur } V \mid w \notin L\}$;
- **La concaténation** (opération non ensembliste) : $L1.L2 = \{w \mid \exists u \in L1, \exists v \in L2 : w = uv\}$;
- **Exposant** (opération non ensembliste) : $L^n = L.L^{n-1}$
- **Fermeture transitive** $L^* = L^0 + L^1 + L^2 + \dots = \bigcup_{i \geq 0} L^i$
- **Fermeture non transitive** $L^+ = L^1 + L^2 + L^3 + \dots = \bigcup_{i \geq 1} L^i$
- **Langage miroir** : $L^R = \{w \mid \exists u \in L : w = u^R\}$.



NOTIONS SUR LES LANGAGE

Propriétés des opérations sur les langages

Soit L, L_1, L_2, L_3 quatre langage définis sur l'alphabet V :

- $L^* = L^+ + \{\epsilon\}$;
- $L_1.(L_2.L_3) = (L_1.L_2).L_3$;
- $L_1.(L_2 + L_3) = (L_1.L_2) + (L_1.L_3)$;
- $L.L \neq L$;
- $L_1.(L_2 \cap L_3) \neq (L_1 \cap L_2).(L_1 \cap L_3)$;
- $L_1.L_2 \neq L_2.L_1$.
- $(L^*)^* = L^*$;
- $L^*.L^* = L^*$;
- $L_1.(L_2.L_1)^* = (L_1.L_2)^*.L_1$;
- $(L_1 + L_2)^* = (L_1^*L_2^*)^*$;
- $L_1^* + L_2^* \neq (L_1 + L_2)^*$



Système générateur de langage (Grammaire)



SYSTÈME GÉNÉRATEUR DE LANGAGE

Grammaire : est un quadruplet (Π, N, S, P) où

N: { alphabet Nom terminal } est un ensemble fini des symboles non terminaux

Π : { alphabet terminal } ensemble fini des symboles terminaux

S $\in N$ est le symbole de départ nommé **Axiome**

P : est un ensemble fini de règle de réécriture (**production**)

➤ Ces règles sont formées d'un terme de gauche α flèche horizontale et terme à droite β

$$\alpha, \beta \in (\Pi \cup N)^*$$

➤ Il existe au moins un symbole de N à gauche

➤ Le côté droit peut être vide selon une règle dite λ - règle

Par convention, on utilisera les lettres

➤ Majuscules pour les non-terminaux,

➤ Minuscules pour représenter les terminaux.

➤ Les règles de la forme $\varepsilon \rightarrow \alpha$ sont interdites.



SYSTÈME GÉNÉRATEUR DE LANGAGE

Exemples

$$G1 = \{\Pi, N, S, P\}$$

$$N = \{S, A, B, C\}, \Pi = \{a, b, c\}, S : \text{Axiome},$$

$$P = \{ S \xrightarrow{1} ASC, S \xrightarrow{2} B, S \xrightarrow{3} bB, B \xrightarrow{4} bB, B \xrightarrow{5} \varepsilon, A \xrightarrow{6} a, C \xrightarrow{7} c \}$$

$$G2 = \{\Pi, N, S, P\}$$

$$N = \{E, A\}, \Pi = \{+, -, /, *, 0, \dots, 9\}, E : \text{Axiome},$$

$$P = \{ E \rightarrow E+E, E \rightarrow E-E, E \rightarrow E*E, E \rightarrow E/E, E \rightarrow A, A \rightarrow 0 \mid 1 \mid 2 \mid 3 \dots \mid 9 \}$$

Dérivation : une séquence de symboles terminaux générée par une grammaire Est une **dérivation**

Soit deux mots f et g de $(\pi \cup N)^*$

▪ On dit que g dérive directement f **SSI** il existe une production $\alpha \rightarrow \beta$ dans P telle que :
 $f = U\alpha V$ et $g = U\beta V$ avec $U, V \in (\pi \cup N)^*$ **Notation** $f \Rightarrow g$

On dit que g dérive le f lorsque g est dérivé directement plusieurs fois de f

Notation $f \xRightarrow{(k)} g$ (k) **nombre de dérivation**

Exemple : abc

$$S \xrightarrow{1} ASC \xrightarrow{6} aSC \xrightarrow{2} aBC \xrightarrow{4} abBC \xrightarrow{5} abC \xrightarrow{7} abc$$



SYSTÈME GÉNÉRATEUR DE LANGAGE

Langage engendré par une grammaire générée

Soit $G = \{\Pi, N, S, P\}$ le langage engendré par g est l'ensemble noté $L(g)$ est défini par

$$L(g) = \{ w \mid S \xRightarrow{*} w \}$$

Exemple 1

$$G = \{\Pi, N, S, P\}$$

$$N = \{S, A, B\}, \Pi = \{a, b\}, S : \text{Axiome},$$

$$P = \{ S \rightarrow A, S \rightarrow a, A \rightarrow AB, A \rightarrow a, B \rightarrow b \}$$

$$L(g) = \{ ab^n : n \geq 0 \}$$

Grammaire équivalente

$$G \text{ équivalente } G' \quad \text{SSI} \quad L(G) = L(G')$$

Mot engendré par une grammaire : deux méthodes

- Par la dérivation successive
- Par arbre de dérivation
 - Sommet : S
 - Branches : les dérivations successives
 - Feuilles : les symboles terminaux

Une Grammaire G est dite ambiguë : si il existe au moins deux arbres de dérivation différents pour un mot w de G



SYSTÈME GÉNÉRATEUR DE LANGAGE

CLASSIFICATION DE CHOMSKY DES GRAMMAIRES

- **Type 3: Grammaire régulière**

Toutes les règles sont sous la forme:

$A \rightarrow \alpha B$ ou $A \rightarrow \alpha$ Avec $A, B \in N$; $\alpha \in \Pi^*$

Grammaire régulière à droite

$A \rightarrow B \alpha$ ou $A \rightarrow \alpha$ Avec $A, B \in N$; $\alpha \in \Pi^*$

Grammaire régulière à gauche

- **Type 2: Grammaire algébrique**

Toutes les règles sont sous la forme

$\alpha \rightarrow \beta$ avec $\alpha \in N$; et $\beta \in (\Pi \cup N)^*$

- **Type 1: Grammaire à contexte lié**

Toutes les règles sont sous la forme:

$\alpha \rightarrow \beta$ avec $\alpha \in (\Pi \cup N)^+$, $\beta \in (\Pi \cup N)^*$ et $|\alpha| \leq |\beta|$

- **Type 0:** Aucune restriction sur la forme des règles

Exemple 1: pour un langage
 $L = \{a^i, i \geq 0\}$

$G = \left\{ \begin{array}{l} S \rightarrow aS \\ S \rightarrow \epsilon \end{array} \right.$ ou $\left\{ \begin{array}{l} S \rightarrow Sa \\ S \rightarrow \epsilon \end{array} \right.$

Exemple 2:

Soit $L = \{a^n b^n / n \geq 1\}$

$G = \left\{ S \rightarrow aSb \mid ab \right.$

Exemple 3:

Soit $L = \{a^n b^n c^n / n \geq 0\}$

$G = \left\{ \begin{array}{l} S \rightarrow \epsilon \\ S \rightarrow aRbc \mid abc \\ R \rightarrow aRTb \\ R \rightarrow aTb \\ Tb \rightarrow bT \\ Tc \rightarrow cc \end{array} \right.$



SYSTÈME GÉNÉRATEUR DE LANGAGE

HIÉRARCHIE DE CHOMSKY

Langage Type 3 $\subset$ Langage Type 2 $\subset$ Langage Type 1 $\subset$ Langage Type 0

